DELETREO MANUAL DE ASL

Reconocimiento de secuencias

Resultados y demostración de la aplicación

Diego José López Campos 23242 · Luis González 23353 · Diego Rosales 23258

CC3084 Data Science · Proyecto 2
12 de octubre de 2026

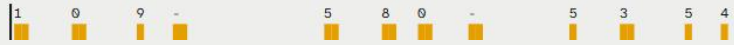
Secuencias de landmarks a texto

Entrada: coordenadas de manos y pose por frame.

Salida: una frase completa de longitud variable.

CTC permite aprender sin etiquetas de cada letra por frame.





Objetivos

General: transcribir a texto el deletreo manual de ASL a partir de landmarks.

1. Un solo preprocesamiento para entrenar y para la app.
2. Separar los datos por persona, para evaluar con gente nueva.
3. Entrenar tres modelos CTC con el corpus completo.
4. Compararlos con métricas de error y de costo.
5. Relacionar los errores con el análisis exploratorio.
6. Una app que prediga y muestre los resultados.

Limpieza compartida con el entrenamiento

01 Selección de canales y mano activa; reflexión de la izquierda.

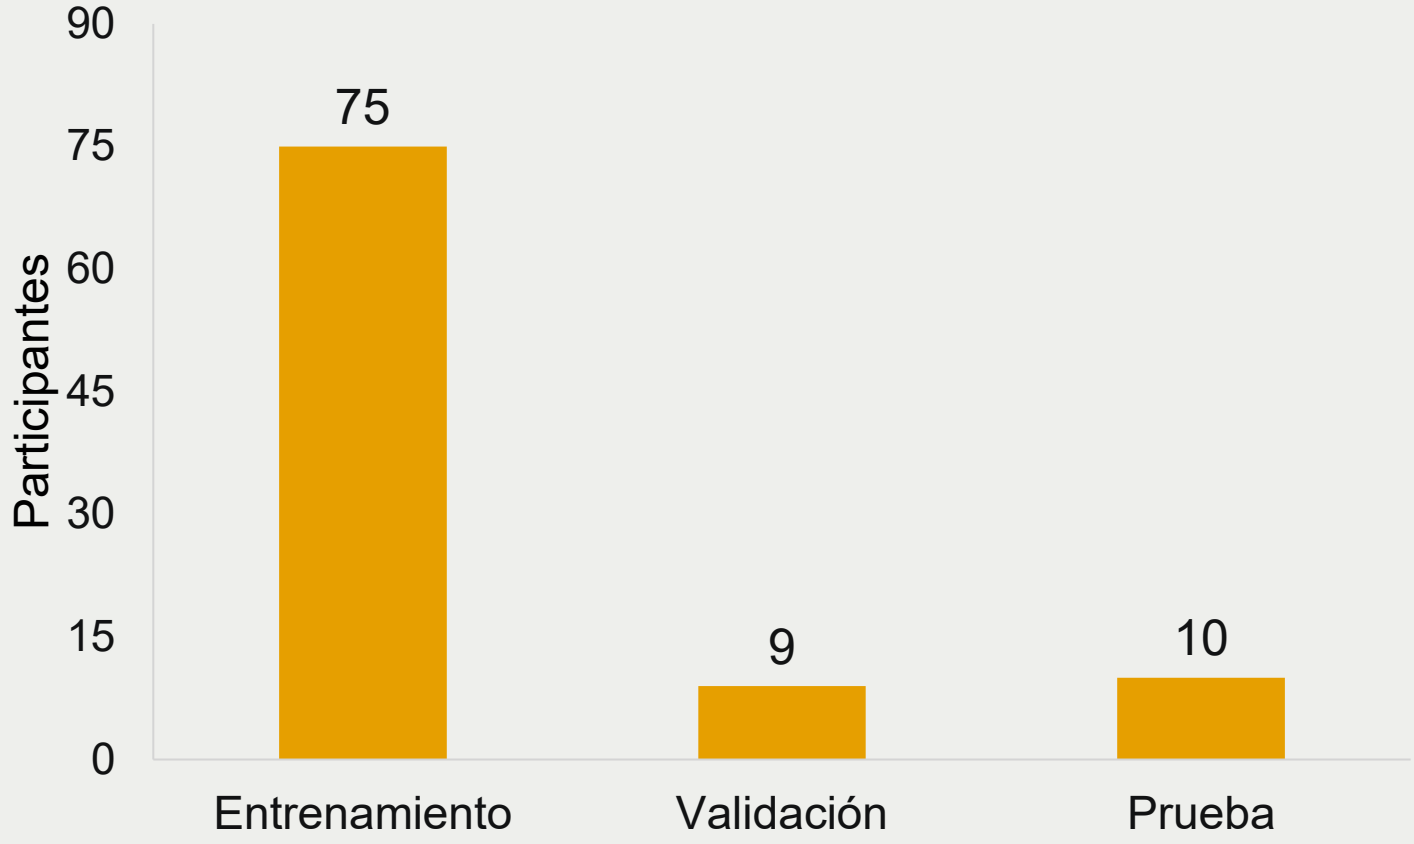
02 Invalidación de picos, recorte e interpolación de huecos ≤ 5 frames.

03 Normalización por muñeca, palma y hombros; máscara de validez.

80 características por frame

63 de la mano activa · 2 de la muñeca · 14 de pose · 1 de la otra mano.
Sin la cara: el deletreo está en la mano. Normalizar quita la posición y el tamaño de cada persona.

Partición por participante



67 208 frases
94 participantes

Los firmantes de prueba quedan fuera del entrenamiento.

Tres arquitecturas con la misma salida

M1 · BiGRU: codificador recurrente bidireccional + CTC.

M2 · TCN: convoluciones temporales dilatadas + CTC.

M3 · Transformer: autoatención temporal + CTC.

Disponibles en la demo: M1, M2 y M3.
Mejor en prueba: M1. Más eficiente: M2.

Hiperparámetros y métricas

Modelo	Configuración elegida	Parámetros	Tasa de aprendizaje
M1 BiGRU	192 unidades · 3 capas	1,67 M	0,001
M2 TCN	192 canales · 6 niveles · kernel 5	1,14 M	0,001
M3 Transformer	d = 192 · 4 capas · 4 cabezas	1,22 M	0,0005

Igual para los tres: AdamW, lotes de 32, hasta 15 épocas, parada temprana de 3, GPU T4.

Métrica principal: distancia de edición normalizada (menor es mejor).

También: CER, frases exactas, error por tipo de carácter y tiempo.

Resultados en prueba: M1 BiGRU es el mejor

0,217

Distancia de edición normalizada · M1

CER 0,216
Frase exacta 10,9 %
1,67 M parámetros

4 181 frases de prueba · 10 participantes no vistos

M2 TCN: 0,247 con la mitad del tiempo · M3 Transformer: 0,256, aún mejorando

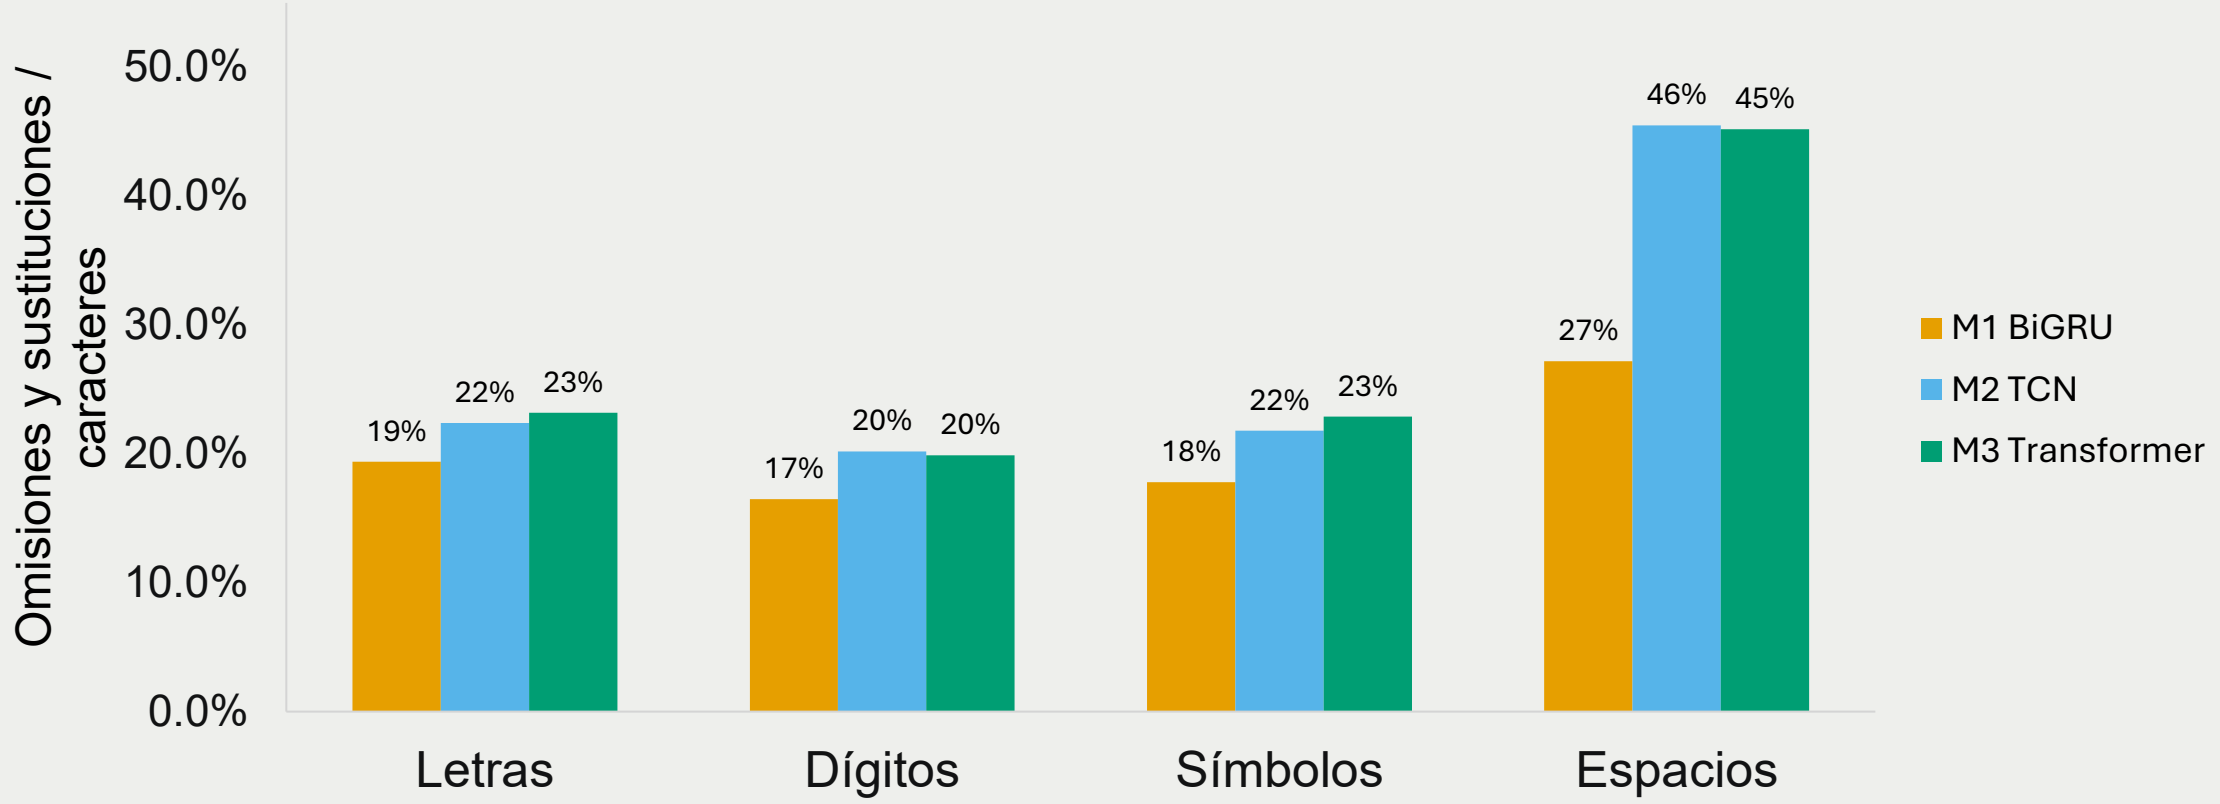
Comparación de los tres modelos

Modelo	Distancia edición	CER	Frases exactas	Entrenamiento
M1 BiGRU	0,217	0,216	10,9 %	21 min
M2 TCN	0,247	0,247	8,1 %	11 min
M3 Transformer	0,256	0,257	5,6 %	24 min

M1 acierta más. **M2** es el más rápido. **M3** necesitaba más épocas.

Menor es mejor en distancia de edición y CER.

Los espacios presentan el mayor error



La frecuencia del carácter no basta para explicar todos los errores.

Conclusiones

CTC funciona: se entrena sin saber dónde empieza cada letra.

M1 BiGRU es el mejor y el que recomendamos para la app.

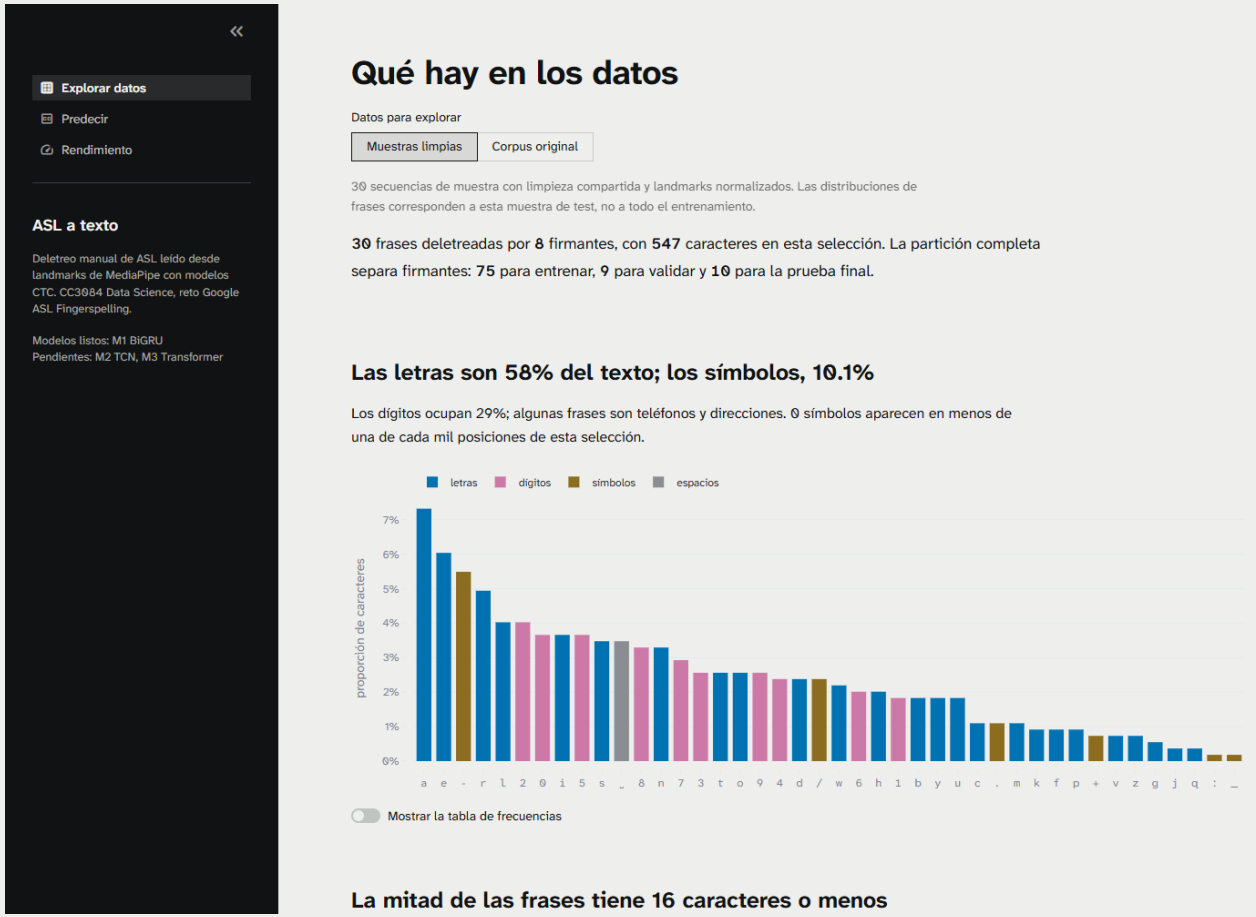
M2 TCN da casi lo mismo con la mitad del tiempo.

El error más grande está en los espacios, no en las letras raras.

Separar por persona dio una evaluación honesta: gente que el modelo nunca vio.

Hoy falla 1 de cada 5 caracteres: falta aumento de datos y un modelo de lenguaje.

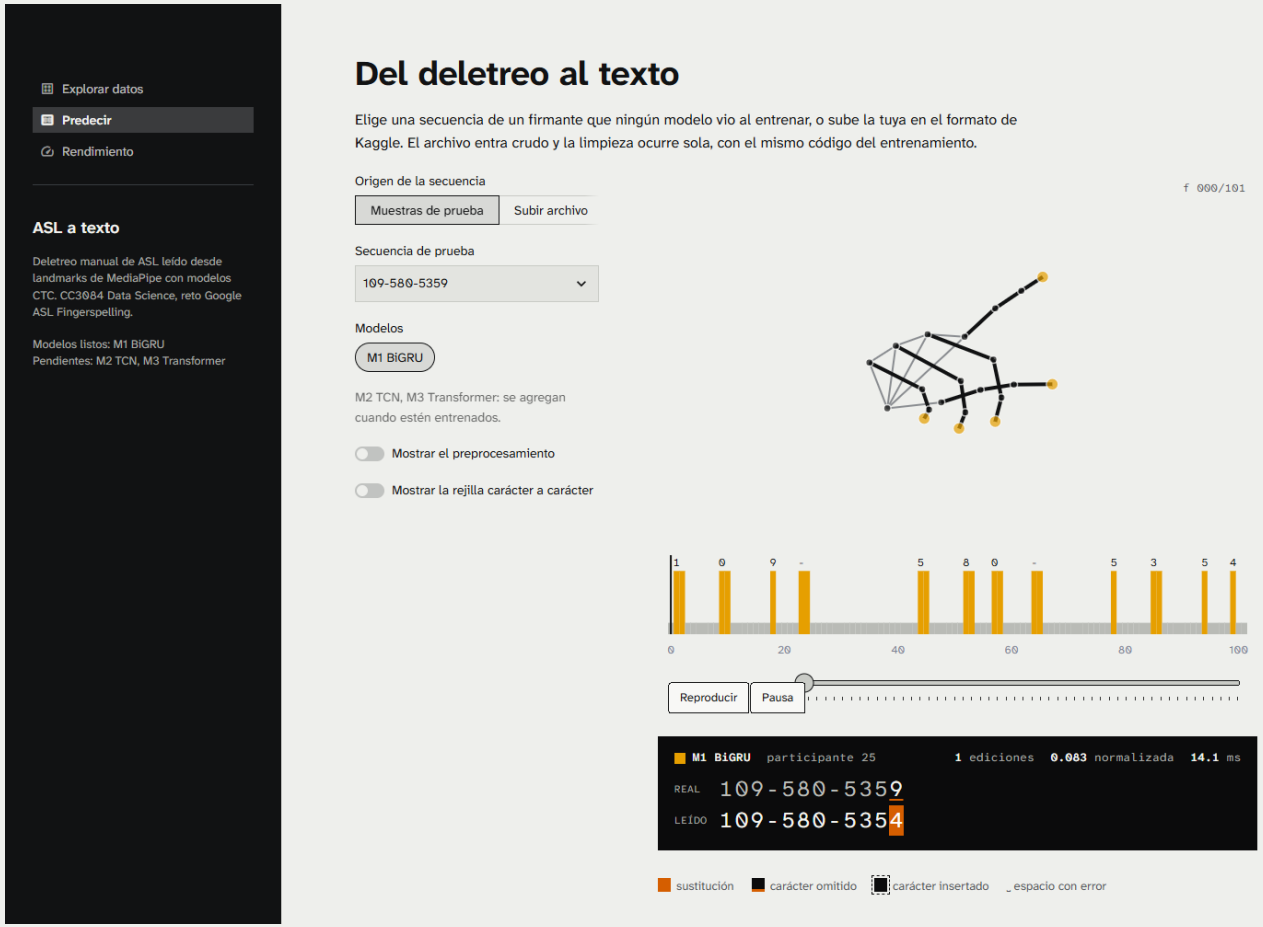
Explorar los datos y su calidad



Muestras limpias y corpus original identificados por separado.

Cobertura, trayectoria y esqueleto de una secuencia.

Predicción sobre una secuencia cruda



Muestra incluida o archivo CSV / Parquet.

Selección de modelos, animación y contraste con la frase real.

Resultados descargables.

Color y legibilidad

Neutros de alto contraste y subtítulos claros sobre negro.

Colores categóricos constantes: M1 naranja, M2 azul, M3 verde.

Nombres, contornos y marcas de error complementan el color.

Fuentes Atkinson Hyperlegible incluidas para funcionar sin internet.

Rendimiento y costo en la misma máquina



Gráficas que se pueden ocultar.

Error por categoría y curvas de entrenamiento.

Medición de CPU con calentamiento, sin recalcular test.

Límites y siguiente paso

Demo: elegir una muestra, reproducir la mano y revisar el subtítulo.

Respaldo: video de la app por si falla la demo en vivo.

Límites: los espacios (27 % de error en M1) y M3 sin converger en 15 épocas.

Siguiente: aumento de datos y modelo de lenguaje.